

¿El modelo mira el balón o mira el césped?

Una auditoría con SHAP de un clasificador ViT sobre escenas de fútbol

Diego Linares

Universidad del Valle de Guatemala

Inteligencia Artificial Responsable

Septiembre de 2026

Resumen

Un clasificador puede acertar la etiqueta por razones equivocadas. Este trabajo audita un Vision Transformer preentrenado en ImageNet-1k [Dosovitskiy et al., 2021] sobre tres fotografías de fútbol que varían únicamente en cuánto contexto rodea al objeto que nombra la clase, y pregunta si la evidencia que sostiene la predicción `soccer ball` se concentra en el balón o se apoya en el escenario correlacionado (césped, jugadores, gradería). Se calculan atribuciones SHAP con un explicador agnóstico al modelo y, en lugar de interpretarlas mirándolas, se las somete a dos pruebas que pueden refutarlas: una curva de supresión frente a un orden aleatorio y ablaciones que aíslan el objeto o el contexto. SHAP resulta fiel en los tres casos –borrar píxeles según su atribución degrada la predicción mucho más rápido que borrarlos al azar– pero el resultado central es otro: la fracción de evidencia que SHAP coloca sobre el balón sobreestima su papel causal en un caso y, en la escena de partido completa, la predicción correcta se sostiene *sin* el balón. La conclusión metodológica es que la masa de atribución no es una medida de necesidad causal, y que un mapa de calor no debería aceptarse como explicación sin una prueba de ablación que lo acompañe.

1. Introducción

La pregunta que motiva este trabajo es concreta y verificable: cuando un clasificador de imágenes responde `soccer ball` ante una escena de fútbol, ¿qué parte de la imagen sostiene esa respuesta?

La pregunta importa porque una etiqueta correcta no garantiza un mecanismo correcto. Un modelo entrenado sobre fotografías naturales aprende regularidades del conjunto de datos, no solo del objeto: los balones de fútbol aparecen casi siempre sobre césped, rodeados de personas con uniforme, en planos abiertos. Si el modelo aprendió a responder al escenario en vez de al objeto, seguirá acertando mientras el escenario se mantenga y fallará en cuanto cambie. Es el fenómeno que Geirhos et al. [2020] llaman *shortcut learning*: soluciones que funcionan en la distribución de entrenamiento y se rompen fuera de ella. Detectarlo requiere mirar el mecanismo, no la métrica agregada.

SHAP [Lundberg and Lee, 2017] es hoy la herramienta estándar para esa inspección. Reparte la diferencia entre la predicción y una línea base entre las partes de la entrada, apoyándose en el valor de Shapley de la teoría de juegos cooperativos [Shapley, 1953]. El resultado es un mapa de calor por píxel, y ahí aparece el problema práctico que este trabajo aborda: un mapa de calor es una imagen persuasiva, y las imágenes persuasivas invitan a creerles. Adebayo et al. [2018] mostraron que mapas de saliencia visualmente convincentes pueden ser insensibles al modelo e incluso a

sus pesos; Kumar et al. [2020] y Sundararajan and Najmi [2020] señalan que las atribuciones de Shapley dependen de decisiones de diseño –sobre todo de la línea base– que rara vez se explicitan.

Este trabajo, por tanto, no se propone únicamente producir explicaciones SHAP, sino someterlas a prueba. El diseño experimental mantiene fija la clase y varía una sola cosa, el tamaño relativo del objeto dentro de la escena, a lo largo de dos órdenes de magnitud. Sobre esas tres imágenes se calculan las atribuciones y luego se verifican con dos procedimientos independientes. Las contribuciones son:

1. Un protocolo reproducible completo: modelo preentrenado, imágenes con licencia libre fijadas por identificador, semillas fijas y tablas del documento generadas desde los resultados, no escritas a mano.
2. Evidencia de que SHAP es fiel en el sentido de la curva de supresión en los tres casos.
3. Un contraejemplo dentro del mismo experimento: en la escena de partido, la predicción correcta *no* depende del objeto que nombra la clase, algo que la lectura directa del mapa de calor no revela.

2. Metodología

2.1. Modelo

Se usa `google/vit-base-patch16-224`, un Vision Transformer ViT-B/16 [Dosovitskiy et al., 2021] con clasificador de 1000 clases sobre ImageNet-1k [Deng et al., 2009]. El modelo se toma tal cual, sin ajuste fino, por dos razones. La primera es de auditoría: es la situación real de quien evalúa un modelo de terceros del que solo puede observar entradas y salidas. La segunda es de reproducibilidad: los pesos son públicos y versionados, así que cualquiera obtiene exactamente el mismo modelo.

ImageNet-1k contiene la clase `soccer ball`, lo que permite formular una pregunta explicativa sin entrenar nada. Contiene además clases que compiten en el mismo escenario (`rugby ball`, `volleyball`, `basketball`, `ballplayer`, `scoreboard`), útiles para leer con qué se confunde el modelo cuando la confianza cae.

2.2. Imágenes y diseño experimental

Las tres imágenes provienen de Wikimedia Commons bajo licencias libres (dos CC0 y una CC BY 2.0) y están fijadas en el código por su título exacto, no por una búsqueda, de modo que la descarga es determinista. Cada archivo se registra con autor, licencia y suma `sha256` en `data/images/manifest.json`.

Todas se preprocesan igual: se escala el lado corto a 224 px y se recorta el centro, sin deformar la escena. Sobre ese recorte de 224×224 se anotó a mano la caja envolvente del balón, ajustada después con un umbral de color. Las tres condiciones varían el área que ocupa el objeto:

- A. Close-up.** El balón llena el encuadre: **69.6 %** del área. Contexto casi ausente.
- B. Balón en el campo.** Balón nítido sobre césped, gradería desenfocada: **19.9 %** del área.
- C. Escena de partido.** Jugadores y árbitros entrando al campo, con el balón en las manos de uno de ellos: **1.1 %** del área.

La variable independiente es entonces el tamaño relativo del objeto, que cambia en un factor de 63 entre A y C, mientras la clase objetivo permanece fija.

2.3. Atribuciones SHAP

Se emplea el *Partition explainer* de la librería **shap** con máscara de imagen por *inpainting* (`inpaint_teia`). La elección es deliberada: este explicador solo necesita la función de predicción, de manera que el transformer se trata como caja negra y no se accede a sus gradientes ni a su atención. Es la condición realista de una auditoría externa y evita atarse a la arquitectura.

Las atribuciones se calculan sobre los *logits* y no sobre la salida *softmax*. Con $p = 0,997$ en el caso A la probabilidad está saturada: casi cualquier perturbación produce un cambio numéricamente nulo y el mapa resultante se aplanan sin que eso signifique ausencia de evidencia. El presupuesto es de 2000 evaluaciones del modelo por imagen, y los tres canales RGB se suman para obtener un único mapa por píxel.

2.4. Cómo se verifica una explicación

Dado que el objetivo es no creerle al mapa de calor por su aspecto, se aplican tres medidas. Las dos últimas son las que pueden refutarlo.

Concentración. Fracción de la evidencia positiva que cae dentro de la caja del balón, dividida entre la fracción de área que esa caja ocupa. Un valor de 1 significa que la evidencia está repartida como lo estaría por azar; valores altos, que se concentra en el objeto.

Curva de supresión. Se borran progresivamente los píxeles en orden de atribución decreciente y se mide $p(\text{soccer ball})$, siguiendo la lógica de Samek et al. [2017] y Petsiuk et al. [2018]. Si las atribuciones son fieles, esa caída debe ser más rápida que la obtenida borrando píxeles en orden aleatorio (promedio de tres semillas). El contenido borrado se sustituye por una versión muy desenfocada de la propia imagen ($\sigma = 15$), que destruye la forma local sin introducir bordes artificiales. Se reporta el área bajo cada curva: menor es mejor.

Ablaciones. La prueba causal directa. *Solo balón* conserva el interior de la caja y desenfoca todo lo demás: mide si el objeto **basta**. *Sin balón* desenfoca únicamente la caja y conserva el resto: mide si el objeto es **necesario**. Las cuatro combinaciones de respuestas distinguen una predicción anclada en el objeto de una anclada en el escenario.

3. Resultados

3.1. Predicciones

Las tres imágenes reciben la misma etiqueta, pero con confianzas que se desploman conforme crece el contexto (Tabla 1).

Imagen	Clase predicha	p	Segunda clase	p
A. Close-up	soccer ball	0.997	golf ball	0.001
B. Balon en el campo	soccer ball	0.983	rugby ball	0.007
C. Escena de partido	soccer ball	0.104	rugby ball	0.084

Cuadro 1: Predicciones del modelo. La clase es la misma en los tres casos; la confianza cae de 0,997 a 0,104 al pasar del close-up a la escena completa. En C la segunda opción (**rugby ball**, 0,084) está prácticamente empatada con la primera.

El caso C merece atención: con $p = 0,104$ el modelo está esencialmente indeciso entre **soccer ball**, **rugby ball** (0,084) y **volleyball** (0,059). Sigue siendo la respuesta correcta, y un sistema que solo registrara la etiqueta la contaría como acierto.

3.2. Atribuciones

La Figura 1 muestra los mapas. En A y B la evidencia positiva se concentra visiblemente sobre el balón, aunque el césped circundante también aporta. En C el panorama cambia: las regiones de mayor atribución se reparten entre los jugadores y el campo, y el balón –pequeño, en manos del árbitro– no domina el mapa.

Evidencia a favor de la clase 'soccer ball' (rojo suma, azul resta)




Figura 1: Atribuciones SHAP para la clase `soccer ball`. Rojo indica píxeles que empujan la predicción hacia la clase; azul, en contra. La resolución espacial la fija el particionado del explicador, no el tamaño del píxel.

3.3. Verificación

Imagen	Concentracion			AUC supresion		Ablacion	
	Area (%)	Masa (%)	Enriq. ($\times$)	SHAP	Azar	Solo balon p	Sin balon p
A. Close-up	69.6	83.4	1.2	0.291	0.704	0.994	0.020
B. Balon en el campo	19.9	53.1	2.7	0.108	0.294	0.865	0.001
C. Escena de partido	1.1	3.5	3.2	0.021	0.042	0.009	0.058

Cuadro 2: Métricas de verificación. *Área*: porcentaje de la imagen ocupado por la caja del balón. *Masa*: porcentaje de la evidencia positiva que cae dentro de esa caja. *Enriq.*: cociente entre ambas. *AUC supresión*: área bajo la curva de borrado guiado por SHAP frente a borrado aleatorio; menor indica atribuciones más fieles. *Ablación*: probabilidad al conservar solo el balón y al borrar solo el balón.

SHAP es fiel. En las tres imágenes el AUC del borrado guiado es sustancialmente menor que el del aleatorio (0,291 vs. 0,704; 0,108 vs. 0,294; 0,021 vs. 0,042). La Figura 2 lo muestra: en A basta borrar el 20 % de los píxeles mejor puntuados para que la confianza pase de 0,997 a 0,413, mientras que borrar ese mismo 20 % al azar la deja en 0,996. Las atribuciones señalan píxeles que de verdad sostienen la predicción, y no se trata de un artefacto del borrado.




Figura 2: Curvas de supresión. La caída más rápida del orden SHAP (rojo) frente al aleatorio (azul) es la prueba de fidelidad. En C el orden aleatorio *sube* por encima de la confianza original, señal de lo inestable que es esa predicción.

La concentración es modesta. El enriquecimiento va de 1,2 a 3,2. En B, el 46,9 % de la evidencia positiva cae *fuera* del balón pese a que el objeto es nítido y central. Leído sin más, esto sugiere que casi la mitad del sustento de la predicción proviene del contexto.

Pero la masa de atribución no equivale a necesidad causal. Las ablaciones corrigen esa lectura. En B, borrar todo el contexto y dejar únicamente el balón apenas mueve la predicción (0,983 $\rightarrow$ 0,865), mientras que borrar solo el balón la aniquila (0,983 $\rightarrow$ 0,001). El objeto es a la vez casi suficiente y estrictamente necesario, aunque SHAP hubiera repartido casi la mitad de la evidencia fuera de él. El caso A se comporta igual: 0,994 conservando solo el balón, 0,020 borrándolo.

El contraejemplo. En C el patrón se invierte. Conservar solo el balón deja $p = 0,009$: el objeto *no basta*. Y borrar el balón deja $p = 0,058$, apenas por debajo del 0,104 original: el objeto *tampoco es necesario*. La predicción correcta se sostiene sobre el escenario –césped, uniformes, disposición de la escena–, no sobre el objeto que la etiqueta nombra. A esto se suma que el borrado aleatorio *aumenta* la confianza hasta 0,166, un comportamiento que no cabe esperar de una predicción bien fundamentada.

4. Discusión

4.1. Acertar por las razones equivocadas

El caso C es exactamente el escenario que preocupa en una auditoría: la etiqueta es correcta, cualquier métrica agregada la contaría como acierto, y sin embargo el mecanismo que la produce no es el que el nombre de la clase sugiere. Con el balón borrado el modelo mantiene su respuesta; con solo el balón visible la abandona. Lo que está reconociendo es una escena de fútbol, no un balón de fútbol.

Conviene notar que la baja confianza (0,104) es en sí misma una señal de alarma disponible sin ninguna herramienta de explicabilidad. Pero la confianza sola no dice *por qué*: sin las ablaciones no habría forma de distinguir entre “el objeto es pequeño y difícil de ver” y “el objeto es irrelevante para esta predicción”. Son diagnósticos distintos que llevan a mitigaciones distintas.

4.2. Implicaciones para el uso de SHAP

Tres lecciones se desprenden del experimento.

Primero, **la masa de atribución no mide necesidad causal**. En B, el 46,9 % de evidencia fuera del balón invitaba a concluir que el contexto pesaba casi tanto como el objeto; la ablación mostró que borrar todo ese contexto cuesta 0,118 de probabilidad, mientras que borrar el objeto cuesta 0,982. Reportar únicamente la fracción de masa –una práctica común– habría producido una conclusión equivocada.

Segundo, **la fidelidad y la utilidad son propiedades distintas**. SHAP superó la prueba de supresión en las tres imágenes, incluida C. Es decir: las atribuciones identifican correctamente los píxeles influyentes y aun así, leídas sin ablaciones, no delatan que la predicción de C está anclada en el contexto. Un método fiel puede producir una explicación que se malinterpreta con facilidad.

Tercero, **la línea base es parte de la explicación**. Las atribuciones responden a “respecto de qué” [Sundararajan and Najmi, 2020, Kumar et al., 2020]: aquí, respecto de una versión con *inpainting* de la propia imagen. Otra línea base –gris uniforme, ruido, media del conjunto– habría dado otros números. Este trabajo la explicita, pero no explora su sensibilidad, y esa dependencia debería declararse siempre que se reporte un mapa SHAP.

Nada de esto contradice el valor de SHAP; sí acota cómo debe leerse. La postura de Rudin [2019] –preferir modelos interpretables por diseño en decisiones de alto riesgo– gana fuerza cuando se comprueba cuánto trabajo adicional cuesta convertir un mapa de calor en una afirmación defendible sobre el mecanismo.

4.3. Una observación sobre la imagen C

La escena de partido es una fotografía tomada en Uganda, en un campo comunitario. El modelo la clasifica con una confianza diez veces menor que a las otras dos. Sería incorrecto extraer de una sola imagen una conclusión sobre sesgo geográfico: la diferencia de confianza se explica

suficientemente por el tamaño del objeto, que es la variable que este diseño manipula. Pero la observación conecta con un hallazgo documentado –de Vries et al. [2019] muestran que los sistemas de reconocimiento de objetos rinden peor sobre imágenes de hogares de ingresos bajos y de países subrepresentados en los datos de entrenamiento– y señala la extensión natural de este trabajo: repetir el protocolo sobre un conjunto estratificado por región y por tamaño de objeto, donde ambos factores puedan separarse.

5. Limitaciones

1. **Tres imágenes no son una muestra.** El diseño ilustra un mecanismo y no estima su frecuencia. Todo lo afirmado vale para estos tres casos.
2. **Las ablaciones producen entradas fuera de distribución.** Una imagen desenfocada en un 98,9% (caso C, *solo balón*) no se parece a nada que el modelo haya visto en entrenamiento. La caída a 0,009 mezcla dos causas: la ausencia de contexto y la rareza de la entrada. Por eso las comparaciones se hacen entre condiciones y no sobre probabilidades absolutas.
3. **Caja envolvente, no segmentación.** La caja del balón incluye algo de fondo en las esquinas, lo que *sobreestima* la evidencia atribuida al objeto. La medida de concentración es en ese sentido conservadora respecto de la conclusión que se defiende.
4. **Una sola línea base.** No se exploró la sensibilidad a la máscara, que es el parámetro más influyente del método.
5. **Aproximación muestreada.** Con 2000 evaluaciones por imagen, el *Partition explainer* aproxima los valores de Shapley mediante un particionado jerárquico; la resolución espacial de los mapas la fija esa partición, no el píxel. La propiedad aditiva se verificó comparando la suma de atribuciones entre presupuestos de 120 y 2000 evaluaciones: coincide en las cuatro cifras decimales.
6. **Sin ajuste fino.** Los resultados describen a ViT-B/16 sobre ImageNet-1k, no a los detectores especializados que se usan en la práctica para analítica deportiva.

6. Reproducibilidad

Todo el material está en <https://github.com/DiegoLinares11/LoopEngineering>. La secuencia completa es:

```
pip install -r requirements.txt
python src/fetch_images.py      # descarga determinista + manifiesto de licencias
python src/classify.py          # -> results/predictions.json
python src/explain_shap.py      # -> results/shap_values.npz, figures/
python src/evaluate.py          # -> results/evaluation.json, figures/
python src/make_tables.py       # -> paper/generado/*.tex
cd paper && pdflatex paper.tex && bibtex paper && pdflatex paper.tex && pdflatex paper.tex
```

Las semillas están fijas (20260902) y cada archivo JSON de resultados incluye las versiones exactas de Python, torch, transformers, shap y numpy con las que se produjo. Las dos tablas del documento se generan desde esos JSON: ninguna cifra del texto se transcribió a mano, de

modo que no pueden desincronizarse del experimento. Las imágenes se identifican por su título en Commons y por su `sha256`. El registro de la interacción con el asistente de IA que acompañó el desarrollo está en `docs/prompt_log.md`.

7. Conclusión

Se auditó un ViT-B/16 sobre tres escenas de fútbol que varían el tamaño relativo del objeto en un factor de 63. SHAP superó la prueba de fidelidad en los tres casos, pero esa fidelidad no impidió que su lectura directa resultara engañosa en ambos sentidos: sobreestimó el papel del contexto donde el objeto era causalmente decisivo (caso B) y no delató que la predicción se apoyaba en el contexto donde el objeto era irrelevante (caso C). La diferencia solo apareció al ablacionar.

La recomendación práctica es sencilla y barata: ningún mapa de atribución debería reportarse como explicación sin al menos una prueba de necesidad y una de suficiencia sobre la región que señala. En este trabajo la verificación completa costó 46 pasadas hacia adelante por imagen –44 de la curva de supresión y 2 de las ablaciones– frente a las 2000 que exigió el mapa de atribución. Las dos que cambiaron la conclusión fueron esas últimas dos.

Referencias

- Julius Adebayo, Justin Gilmer, Michael Muelly, Ian Goodfellow, Moritz Hardt, and Been Kim. Sanity checks for saliency maps. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.
- Terrance de Vries, Ishan Misra, Changhan Wang, and Laurens van der Maaten. Does object recognition work for everyone? In *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2019.
- Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2009.
- Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations (ICLR)*, 2021.
- Robert Geirhos, Jörn-Henrik Jacobsen, Claudio Michaelis, Richard Zemel, Wieland Brendel, Matthias Bethge, and Felix A. Wichmann. Shortcut learning in deep neural networks. *Nature Machine Intelligence*, 2(11):665–673, 2020.
- I. Elizabeth Kumar, Suresh Venkatasubramanian, Carlos Scheidegger, and Sorelle Friedler. Problems with shapley-value-based explanations as feature importance measures. In *International Conference on Machine Learning (ICML)*, 2020.
- Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- Vitali Petsiuk, Abir Das, and Kate Saenko. Rise: Randomized input sampling for explanation of black-box models. In *British Machine Vision Conference (BMVC)*, 2018.

- Cynthia Rudin. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1(5):206–215, 2019.
- Wojciech Samek, Alexander Binder, Grégoire Montavon, Sebastian Lapuschkin, and Klaus-Robert Müller. Evaluating the visualization of what a deep neural network has learned. *IEEE Transactions on Neural Networks and Learning Systems*, 28(11):2660–2673, 2017.
- Lloyd S. Shapley. A value for n-person games. *Contributions to the Theory of Games*, 2(28):307–317, 1953.
- Mukund Sundararajan and Amir Najmi. The many shapley values for model explanation. In *International Conference on Machine Learning (ICML)*, 2020.